

Value Iteration Algorithm

- For each state s , figure out the expected reward of starting in s and acting optimally.

→ Use the Bellman Equation (value function)

↳ Value function near high-reward states will be large

$$V^*(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^*(s')] \quad \text{(future reward)}$$

Annotations for the equation:

- \max_a : get only "best" action
- $\sum_{s'}$: transition function
- $T(s, a, s')$: state I'm in, action I took, state I ended up in
- $R(s, a, s')$: reward
- $V^*(s')$: value function for starting in s'

The reason this is needed is because we can't remove stochasticity completely: the agent has a high chance of performing the desired action, but there's also a chance that they don't.

Algorithm:


1. Initialize all $V^*(s)$ to 0 (except the reward states)
2. While not converged
 - a. For each state compute $V^*(s)$

$$V_{k+1}^*(s) = \max_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_k^*(s')]$$

convergence criterion

Policy extraction: $\max \rightarrow \operatorname{argmax}$

$$\pi^*(s) = \operatorname{argmax}_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_k^*(s')]$$

Το πρόβλημα με το αυτοκίνητο  robot

	1	2	3
2			10
1			-10

intended dir: 0.8

⊥ dir: 0.1

backwards: 0.0

$\gamma = 0.9$

$\alpha) \underline{k=1}$:

$$\begin{pmatrix} 0 & 0 & 10 \\ 0 & 0 & -10 \end{pmatrix} \text{ (initialization)}$$

$\underline{k=2}$: Τα $(1,1)$, $(2,1)$ δεν γίνονται update γιατί οτις γείτονες τους έχουν μηδενικά.

$(1,2)$: Βέλτιστη δράση = αριστερά, γιατί αν πάει πάνω τότε έχει 10% πιθανότητα να καταλήξει στο -10

$(2,2)$: Βέλτιστη δράση = δεξιά, με $V = 0.9(0.8 \times 10 + 0.1 \times 0 + 0.1 \times 0) = 7.2$

$$\begin{pmatrix} 0 & 7.2 & 10 \\ 0 & 0 & -10 \end{pmatrix}$$

$\underline{k=3}$: (Τιμικά η εκτίμηση αλλάζει μέχρι $k=2$)

$(1,1)$: No updates




$(1,2)$: Βέλτιστη δράση = πάνω:

$$V = 0.9(7.2 \times 0.8 + (-10) \cdot 0.1 + 0 \times 0.1) = 4.284$$

$(2,1)$: Βέλτιστη δράση = δεξιά: $V = 0.9(7.2 \times 0.8 + 0 \times 0.1 + 0 \times 0.1) = 5.184$

$(2,2)$: Βέλτιστη δράση = δεξιά: $V = 0.9(10 \times 0.8 + 0 \times 0.1 + \overset{\text{Τίμω}}{7.2} \times 0.1) = 7.848$

β) Σε ό,τι αφορά το (β) γράφος των δόμων, υπάρχουν 2 δυνατές προεξίξεις. Σε κάθε προεξίξη, ισχύουν:



Προεξίξη #1: Αρχικά $V = 0$ παντού. Μετά το παιχνίδι (α):

$$V_2 = V_1 + \alpha(U_1 - V_1) \Rightarrow V_2 = -10\alpha, \text{ για τα } (1,1), (1,2),$$

0 για τα άλλα

Μετά το (β):

0	0	10
-10α	-10α	-10

$$V_3 = -10\alpha + \alpha(10 + 10\alpha) = 10\alpha^2$$

0	10α	10
$10\alpha^2$	$10\alpha^2$	-10

Μετά το (γ):

0	10α	10
$10\alpha^2$	$10\alpha^2$	-10

$$\rightarrow$$

10α	$20\alpha - 10\alpha^2$	10
$10\alpha + 10\alpha^2 - 10\alpha$	$10\alpha^2$	-10

Αρα οι τιμές των κελιών (1,1) και (2,2) είναι $10\alpha + 10\alpha^2 - 10\alpha^3$ και $20\alpha - 10\alpha^2$ αντίστοιχα, όπου α : learning rate

Προεξίξη #2: Το (1,1) εμφανίζεται και στα 3 παιχνίδια, άρα

$$V(1,1) = \frac{-10 + 10 + 10}{3} = 10/3$$

Το (2,2) εμφανίζεται στα 2 παιχνίδια με reward +10, άρα

$$V(2,2) = \frac{+10 + 10}{2} = 10$$

First visit MC vs Every visit MC