

MAP + prior = Regularization

Έστω ένα σύνολο δεδομένων $(x_1, y_1), \dots, (x_N, y_N)$ τέτοια, ώστε

$$y_i = w_0 + w_1 x_i + \varepsilon_i, \text{ όπου}$$

ε_i : Γκαουσιανός θόρυβος με $\varepsilon_i \sim N(0, \sigma^2)$.

Βάσει αυτού ισχύει $y_i \sim N(\hat{y}_i, \sigma^2)$, όπου $\hat{y}_i = w_0 + w_1 x_i$

Η βέλτιστη επιλογή των w_0, w_1 προκύπτει μέσω της μεγιστοποίησης της πιθανότητας $L(w_0, w_1 | y_1, \dots, y_N)$ η οποία δίνεται ως

$$L = \prod_{i=1}^N \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left[-\frac{1}{2\sigma^2} (y_i - \hat{y}_i)^2\right] \equiv P(y_1, \dots, y_N | w_0, w_1)$$

Από το Θ. Bayes ισχύει $p(w_0, w_1 | y_1, \dots, y_N) \sim L \cdot p(w_0, w_1)$,

όπου $p(w_0, w_1)$ = prior για τις παραμέτρους w_0, w_1 .
Μεγιστοποιώντας την posterior $p(w_0, w_1 | y_1, \dots, y_N)$ δεδομένης μιας prior κατανομής για τις παραμέτρους w_0, w_1 προκύπτουν οι γνωστοί regularizers:

- Έστω Gaussian prior, δηλαδή $p(w_i) \sim N(0, s^2)$. Τότε

$$P(\theta | D) \sim P(D | \theta) \cdot P(\theta) \Rightarrow$$

$$\ln P(\theta | D) \sim \ln \left[\prod_{i=1}^N N(y_i | w_0, w_1, \sigma^2) N(w_0 | 0, s^2) N(w_1 | 0, s^2) \right]$$

$$= -\frac{1}{2} \ln(2\pi s^2) - \frac{1}{2} \frac{w_0^2}{s^2} - \frac{1}{2} \ln(2\pi \sigma^2) - \frac{1}{2} \frac{w_1^2}{\sigma^2} + \sum_{i=1}^N \ln N(y_i | w_0, w_1, \sigma^2)$$

$$= -\ln(2\pi s^2) - \frac{1}{2} \frac{w_0^2 + w_1^2}{s^2} - \frac{N}{2} \ln(2\pi \sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

$$= -\ln(2\pi s^2) - \frac{N}{2} \ln(2\pi \sigma^2) - \frac{1}{2\sigma^2} \left[\sum_{i=1}^N (y_i - \hat{y}_i)^2 + \frac{\sigma^2}{s^2} \|\vec{w}\|^2 \right]$$

Προσώτε, λοιπόν,

$$\vec{w} = \underset{\vec{w}}{\operatorname{argmin}} p(\theta|D) = \underset{\vec{w}}{\operatorname{argmin}} \left[\sum_i (y_i - \hat{y}_i)^2 + \frac{\sigma^2}{S^2} \|\vec{w}\|^2 \right],$$

δηλαδή L2-regularization με $\lambda = \sigma^2/S^2$.

• Έστω Laplacian prior, δηλαδή $p(w_i) \sim L(0, b)$. Τότε

$$\ln p(\theta|D) = \ln \left[\prod_{i=1}^N N(y_i | w_0, w_1, \sigma^2) L(w_0 | 0, b) L(w_1 | 0, b) \right]$$

$$= -\ln(2b) - \frac{|w_0|}{b} - \ln(2b) - \frac{|w_1|}{b} - \sum_{i=1}^N \ln N(y_i | w_0, w_1, \sigma^2)$$

$$= -2\ln(2b) - \frac{|w_0| + |w_1|}{b} - \frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

$$= -2\ln(2b) - \frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \left[\sum_{i=1}^N (y_i - \hat{y}_i)^2 + \frac{2\sigma^2}{b} (|w_0| + |w_1|) \right]$$

Προσώτε, λοιπόν,

$$\vec{w} = \underset{\vec{w}}{\operatorname{argmin}} p(\theta|D) = \underset{\vec{w}}{\operatorname{argmin}} \left[\sum_{i=1}^N (y_i - \hat{y}_i)^2 + \frac{2\sigma^2}{b} \sum_{j=0}^1 |w_j| \right],$$

δηλαδή L1-regularization με $\lambda = 2\sigma^2/b$.