

Οκτώβριος 2020

Ζήτημα 1

(1A) ΓΓΜ: $E(y) = X\beta$

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

H_1 : τουλάχιστον ένα $\beta_j \neq 0$.

$$SSE_0$$

$$SSE_1$$

$$F = \frac{(SSE_0 - SSE_1) / k}{SSE_1 / (n - k - 1)} \sim F_{k, n-k-1}$$

αρχικά για R^2 : $F = \frac{R^2 / k}{(1 - R^2) / (n - k - 1)}$ αργότερα για R^2 : $\frac{R^2}{1 - R^2} = \frac{SSE_0 - SSE_1}{SSE_1}$

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

για το $H_0: E(y) = \beta_0 \rightarrow$ αυτό ισχύει $\hat{\beta}_0 = \bar{y}$

$$\hat{y}_i = \hat{\beta}_0 \quad \text{και} \quad SSR_0 = \sum (\hat{\beta}_0 - \bar{y})^2 = 0 \rightarrow R^2_0 = \frac{SSR_0}{SST} = 0$$

$$SSE_0 = SST - SSR_0 = SST$$

$$SSE_1 = SST - SSR_1 = SST - SSR_1$$

$$SST - SSR_0 = SST$$

\rightarrow εφαρμόζει μόνο αυτό δεδομένα

$$\text{και (1)} \quad \frac{SSE_0 - SSE_1}{SSE_1} = \frac{SST - SST + SSR_1}{SST - SSR_1} = \frac{\frac{SSR_1}{SST}}{1 - \frac{SSR_1}{SST}} = \frac{R^2_1}{1 - R^2_1} \quad \checkmark$$

(1B) $E(y) = \beta_0 + \beta_1 X_1$

• $H_0: H_0: E(y) = \beta_0 + \beta_1 X_1$

$H_1: H_1: E(y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2$

ελέγχος $F: \frac{(SSE_0 - SSE_1) / 1}{SSE_1 / (n - 2 - 1)}$

$$\sim F_{1, n-2-1} = F_{1, n-3}$$

επαλήθευση H_1

Αν το p-value του F-test προκύψει στατιστικά σημαντικός (π.χ. < 0.05) τότε απορρίπτουμε την H_0 (H_0) και εστιάζουμε H_1 (μια φορά M_1).

• Βρίσκω R^2 , \bar{R}^2 (adjusted), $R^2_{\text{prediction}}$

• Ελέγχω τιμές AIC

• Ελέγχω τιμές C_p

(• ίσως ελέγξω μεθόδους)

ZΗΤΗΜΑ 2

$$n=21, \quad Y \sim X_1, X_2$$

$$(i) \quad E(Y) = \beta_0 + \beta_1 X_1 + \beta_2 X_2, \quad y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2$$

$$\text{Δίνεται } S = 0.172, \quad \{r_{X_1 X_2} = 0.782\}, \quad R^2 = 90.3\%$$

Μεταβ.	$\hat{\beta}$	$se(\hat{\beta})$	t	p-τιμή	VIF
Συνάρτ.	-0.752	0.273	-2.75	0.013	
X_1	0.035	0.006			
X_2	0.063	0.020			

$VIF_j = \frac{1}{1 - R_j^2}$ όπου R_j^2 είναι η R^2 από την regression της j -της μεταβ. στις υπόλοιπες μεταβ. $X_1, X_2, \dots, X_{j-1}, X_{j+1}, \dots, X_k$

$S = \sqrt{MSE} = \sqrt{\frac{SSE}{n-p}} \rightarrow SSE = (n-p) \cdot S^2$ όπου S γνωστό και $p=3$ (αριθμός παραμέτρων)

$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \rightarrow SST = \frac{SSE}{1 - R^2}$ όπου SSE γνωστό από πριν και R^2 από πριν

$R_j^2 = \frac{SSR_j}{SST} \rightarrow$ από φάσμα το $SSR_j \rightarrow SSE$ απεικονίζεται τη j -μεταβ. από το υπόλοιπο

Βγαίνοντας 1 μεταβ. προκύπτει από γραμμικό μοντέλο και έχουμε τότε:

$$SSR_j = \hat{\beta}_j^2 \cdot S_{xx_j}$$

↑
μεταβ. που μένει

Από βγαίνοντας τη X_1 θέλω να υπολογίσω το R^2 και έχω:

$$SSR = \hat{\beta}_2^2 \cdot S_{X_1 X_2}$$

↑
γνωστό

$$r_{X_1 X_2} = \frac{S_{X_1 X_2}}{\sqrt{S_{X_1 X_1} \cdot S_{X_2 X_2}}} = \frac{\sum (x_{1i} - \bar{x}_1)(x_{2i} - \bar{x}_2)}{(\sum (x_{1i} - \bar{x}_1) \cdot \sum (x_{2i} - \bar{x}_2))^{1/2}} \quad (1)$$

από $se(\hat{\beta}_1) = \frac{S}{\sqrt{S_{X_1 X_1}}}$ και ομοίως $se(\hat{\beta}_2) = \frac{S}{\sqrt{S_{X_2 X_2}}}$ (2)

από (1) και (2) βρίσκω $S_{X_1 X_2}$ (και τα $S_{X_1 X_1}, S_{X_2 X_2}$)

Για το VIF: $X_2 \sim X_1$ δηλ. κάνω regress των X_2 με τις υπόλοιπες μεταβ. (δηλ X_1)

από $r_{X_1 X_2}^2 = R^2$ από την regression δηλ. $R_j^2 = R_{X_1 X_2}^2$ και $VIF_1 = VIF_2 = \frac{1}{1 - r_{X_1 X_2}^2}$

$$= \frac{1}{1 - 0.782^2} \approx 2.574$$

$$(ii) e_{21} = -0.287, h_{21,21} = 0.276, D_{21} = \frac{r_{21}^2 h_{21,21}}{p(1-h_{21,21})}$$

Αν $D_{21} \gg 1$ τότε θεωρείται σημείο επιρροής.

$$r_i^2 = \frac{e_i^2}{S^2(1-h_{ii})}$$

↓
μικρό

↓
μικρό

για σημείο $i=21$

↑
παράμετροι

$$r_{21}^2 = \frac{e_{21}^2}{S^2(1-h_{21,21})} \approx 3.846, D_{21} = \frac{3.846 \cdot 0.276}{3 \cdot (1-0.276)} \approx 0.483.$$

Ημετέρο του 1 ότι με βάση Cook Distance το σημείο $i=21$
δεν είναι σημείο επιρροής.